

特征工程技术洞察 02

多维缩放 (MDS)

Jiangsheng Yu

05/06/2024

内积矩阵和距离矩阵的定义

向量 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ 或者矩阵 $A = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ 的格拉姆矩阵或内积矩阵定义为

$$\mathbf{G}_{n \times n} = A^\top A, \text{ 其中 } A = (\mathbf{x}_1, \dots, \mathbf{x}_n)$$

显然，格拉姆矩阵 \mathbf{G} 的 (i, j) 元素 g_{ij} 即是 $\mathbf{x}_i, \mathbf{x}_j$ 的内积 $\langle \mathbf{x}_i, \mathbf{x}_j \rangle = \mathbf{x}_i^\top \mathbf{x}_j$ 。

用 $d(\mathbf{x}, \mathbf{y})$ 表示 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ 之间的距离 (distance)。譬如， $d(\mathbf{x}, \mathbf{0})$ 是向量 \mathbf{x} 到原点的距离，即 \mathbf{x} 的长度。对于一组给定的向量 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ ，其距离矩阵 (distance matrix) $\Delta_{n \times n} = (d_{ij})$ 定义为

$$d_{ij} = d(\mathbf{x}_i, \mathbf{x}_j)$$

内积矩阵和距离矩阵的关系

(距离矩阵与内积矩阵的关系) 设向量 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$ 是中心化的, 即满足 $\mathbf{x}_1 + \dots + \mathbf{x}_n = \mathbf{0}$, 则其内积矩阵 $\mathbf{G} = (g_{ij})$ 可由欧氏距离矩阵 Δ 构造如下。

$$\mathbf{G} = -\frac{1}{2}\mathbf{H}\Delta^2\mathbf{H}$$

其中,

$$\Delta^2 = (d_{ij}^2)_{n \times n} = (\|\mathbf{x}_i - \mathbf{x}_j\|_2^2)_{n \times n}$$

$$\mathbf{H} = \mathbf{I}_n - \frac{1}{n}\mathbf{E}_n$$

多维缩放 (MDS) 问题

在几何上，如何把样本的维数降下来，同时又尽量不破坏它们之间的距离关系？
多维缩放 (multidimensional scaling, MDS) 就是实现这类数据表示的方法。

已知样本 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 的距离矩阵 $\Delta = (d_{ij})_{n \times n}$ ，譬如，欧氏距离矩阵。我们要寻找的数据表示 $\mathbf{y}_1, \dots, \mathbf{y}_n \in \mathbb{R}^k$ 要尽可能地保证

$$\|\mathbf{y}_i - \mathbf{y}_j\|_2 = d_{ij}, \forall i, j \in \{1, \dots, n\}$$

换句话说，就是求解下面的全局最优化问题。

$$\operatorname{argmin}_{\mathbf{y}_1, \dots, \mathbf{y}_n \in \mathbb{R}^k} \sum_{i < j} (\|\mathbf{y}_i - \mathbf{y}_j\|_2 - d_{ij})^2$$

历史背景

实际上，该问题探讨的是如何仅仅通过给定的距离矩阵 Δ 重新表示样本，使其距离矩阵就是 Δ 。重构样本的维数 k 是由 Δ 决定的。

1938 年，美国数学家盖尔·杨 (Gail Young, 1915—1999) 和阿尔斯通·斯科特·豪斯霍尔德 (Alston Scott Householder, 1904—1993) 利用由欧氏距离矩阵 Δ 构造的内积矩阵的谱分解给出了一个答案。



杨和豪斯霍尔德

多维缩放 (MDS) 算法

给定欧氏距离矩阵 Δ ，下述算法给出MDS问题的一个解。

(1) 由 Δ 构造内积矩阵 G 。

(2) 计算 G 的谱分解

$$\begin{aligned} G &= V\Lambda V^T \\ &= V\text{diag}(\lambda_1, \dots, \lambda_r)V^T \end{aligned}$$

(3) 我们得到MDS问题的一个解

$$\begin{aligned} Y &= \Lambda^{\frac{1}{2}} V^T \\ &= \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_r})V^T \end{aligned}$$

显然，MDS问题的解并不唯一，以下也是它的一个解。

$$Y_{n \times n} = V\Lambda^{\frac{1}{2}} V^T$$

MDS的例子

从普林斯顿大学 WordNet 词汇语义知识库或者类似的知识图谱中，可以抽取词汇距离（例如，两个概念节点之间按照某种关系的最短路径的长度）。多维缩放算法使得这些词汇或概念在欧氏空间里得以向量化，为自然语言处理提供了数据表示。


虚构的词汇距离数据

Δ	狗	猫	人类	机器人	车
狗	0	3	8	12	16
猫	3	0	9	13	16
人类	8	9	0	6	15
机器人	12	13	6	0	4
车	16	16	15	4	0

MDS的例子

二维词汇向量

	狗	猫	人类	机器人	车
y_1	6.26	6.49	2.49	-5.50	-9.74
y_2	1.70	3.13	-5.52	-2.48	3.17



在平面内的二维词汇向量

以上的讨论都是基于 Δ 是欧氏距离矩阵。在多维缩放中，采用欧氏距离的作法是值得商榷的。譬如，数据若分布在一个球面上，用欧氏距离来实现多维缩放就是错误的。一般地，数据在空间的分布是未知的，甚至连数据所在的空间我们也是知之甚少。若要考虑比球面更一般的几何对象，就需要流形 (manifold) 的概念。